

Aprendizado Federado na Saúde

Autor : Mário A. Costa Júnior

Classe : MO809 Tópicos em Computação Distribuída

Prof. : Dr. Luiz Fernando Bittencourt

FedHealth

FedHealth: A Federated Transfer Learning Framework for Wearable Healthcare

Yiqiang Chen, Jindong Wang , Chaohui Yu, Wen Gao, Xin Qin

Beijing Key Lab. of Mobile Computing and Pervasive Devices, Inst. of Computing Tech., CAS
University of Chinese Academy of Sciences, Beijing, China
Pengcheng Laboratory, Shenzhen, China
Microsoft Research Asia, Beijing, China
yqchen@ict.ac.cn, jindong.wang@microsoft.com

FedHealth

Saúde Inteligente

- Vantagens:

Variedade de sensores.

Sensores de fácil acesso aos usuários.

Grande volume de dados.

Aprendizado obtém bons resultados.



FedHealth

Saúde Inteligente

- Desvantagens:
 - Segurança dos dados.
 - Falha ao obter modelos personalizados



FedHealth


Objetivo

Este trabalho tem como objetivo criar o primeiro framework de aprendizado de transferência federado estruturado para cuidados de saúde.

FedHealth

Objetivo

A coleta dos dados será realizada através de vestíveis



FedHealth

Atuação


Monitora esportes de alto rendimento.

Doenças como:

- parkinson.
- Doenças em pequenos vasos cerebrais.
- Detecção de ataque cardíaco.

Detecção de quedas.

Entre outros.



FedHealth

Objetivo

Para chegar a este objetivo e enfrentar os desafios apresentados, a pesquisa se concentra no uso das seguintes técnicas:

- Agregação de dados, através do aprendizado federado.
- Criação de modelos personalizados, através da transferência de aprendizado.

FedHealth

Modelo Atual

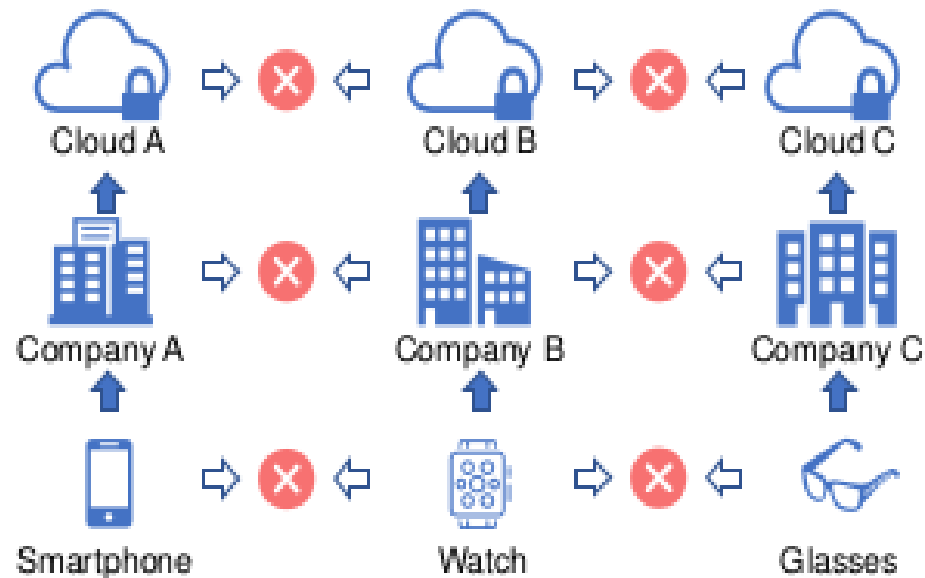


Imagem retirada da publicação: FedHealth: A Federated Transfer Learning Framework for Wearable Healthcare

Y Chen, X Qin, J Wang, C Yu, W Gao - IEEE Intelligent Systems, 2020 - ieeexplore.ieee.org

FedHealth

Modelo proposto




Imagem retirada da publicação: FedHealth: A Federated Transfer Learning Framework for Wearable Healthcare

Y Chen, X Qin, J Wang, C Yu, W Gao - IEEE Intelligent Systems, 2020 - ieeexplore.ieee.org

FedHealth

Transferência de aprendizado

Algoritmo do procedimento de treinamento do FedHealth

Entrada: Dados de diferentes usuários $\{D1, D2, \dots, DN\}$, η

Saída: Modelo do usuário personalizado f_u

- 1: Constroi um modelo na nuvem f_S – usando Eq.(2), dados públicos.
- 2: Distribui f_S para todos via usuários por criptografia homomórfica.
- 3: Treina os modelos do usuário – usando Eq. (3).
- 4: Envia todos os modelos dos usuários para o servidor usando criptografia homomórfica. Em seguida, o servidor atualiza seu modelo alinhando com o modelo de usuário – agregação.
- 5: Distribui f'_S para os usuários e realiza a transferência de aprendizado em cada usuário para manter o seu modelo personalizado F_u – usando Eq.(6).
- 6: Repete continuamente o procedimento acima ao receber novos dados.

Eq.(2)

$$\arg \min_{\Theta} L = \sum_{i=1}^n l(y_i, f_s(x_i)).$$

Eq.(3)

$$\arg \min_{\Theta_u} L_1 = \sum_{i=1}^{n_u} l(y_i^u, f_u(x_i^u)).$$

Eq.(6)

$$\arg \min_{\Theta_u} L_u = \sum_{i=1}^{n_u} l(y_i^u, f_u(x_i^u)) + \eta l_{CORAL}.$$

S = usuário.

D = dados do sensor.

$l(.,.)$ = perda para rede.

$\{x_i, y_i\}_{i=1}^n$ = amostra de dados do servidor com

seus pesos.

θ = parametros a serem

aprendidos (pesos e viés).

f_S = modelo servidor irá aprender.

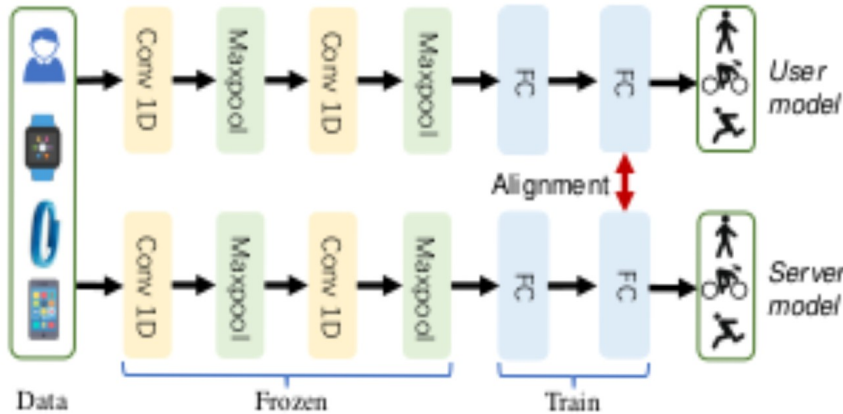
f'_S = novo modelo do servidor.

F_u = modelo do usuário.

$$l_{CORAL} = \frac{1}{4d^2} \|C_S - C_T\|_F^2$$

FedHealth


Transferência de aprendizado



Rede Neural Convolucional (CNN)
Duas camadas convolucionais (conv1, conv2).
Duas camadas max-pooling layers (pool1, pool2).
Duas camadas totalmente conectadas (fc1, fc2).
Uma camada softmax layer para classificação.

FedHealth

Transferência de aprendizado




Rede desenhada para reconhecimento de atividades humanas e.g.: correr, andar, entre outras.

Quanto mais ciclos mais personalizado o modelo fica.

Permite que o processo adote outra técnica de aprendizado de máquina como por exemplo, o uso de uma árvore de decisão para o aumento de gradiente, pode ser integrada a estrutura;

FedHealth

Transferência de aprendizado



Para transferência de modelos, foi identificada que as camadas de convolução, visam a extração de recursos de baixo nível sobre o reconhecimento das atividades, sendo assim, congelaram as camadas de conv 1D e Maxpool não permitindo a repropagação dos parâmetros – personalização do modelo.

Quanto às camadas totalmente conectadas fc1 e fc2, por serem de nível superior, foi identificada que elas estariam ligadas a recursos específicos das atividades e usuários, o que permitiu a atualização dos seus parâmetros durante o treinamento.

FedHealth

Experimento

Reconhecimento de algumas atividades humanas como:

- Andar.
- Subir escadas.
- Descer escadas.
- Sentar.
- Ficar parado.
- Descansar.

FedHealth

Experimento

Aparelho Utilizado:

- Samsung Galaxy SII.

Sensor utilizado:

- Acelerometro.
- Giroscópio.

Dados obtidos foram divididos da Seguinte forma:

- 70% de treinamento.
- 30% de teste.

Amostra extraída:

- 30 Voluntários

FedHealth

Experimento

Treinamento foi realizado:

- Servidor.
- usuário final.

Adotada a CNN para treinamento e predição, composta de:

- 2 camadas convolucionais.
- 2 camadas pooling.
- 3 camadas totalmente conectadas.

A rede adotou a tamanho de convolução de 1×9 .

Usa mini-batch SGD (Stochastic Gradient Descent) para otimizar.

Taxa de aprendizado em 0.01.

Lote com tamanho de 64.

Conta com 80 épocas de treinamento.

FedHealth

Acurácia (5 sujeitos isolados)

Subject	KNN	SVM	RF	NoFed	FedHealth
P1	83.8	81.9	87.5	94.5	98.8
P2	86.5	96.9	93.3	94.5	98.8
P3	92.2	97.2	88.9	93.4	100.0
P4	83.1	95.9	91.0	95.5	99.4
P5	90.5	98.6	91.6	92.6	100.0
AVG	87.2	94.1	90.5	94.1	99.4

Tradicionais modelo de aprendizado
k-Nearest Neighbors (KNN)
Support Vector Machine” (SVM)
Ran-dom forest (RF)


NoFed – sem aprendizado federado

Cada experimentos foi realizados 5x
(acurácia média).

Comparado ao NoFed, melhora
significativamente o resultados médios em
5,3%.

FedHealth

Diferentes métodos de transferência de aprendizado



Fine-tuning - sem reduzir explicitamente a divergência de distribuição entre os domínios.

MMD (Maximum Mean Discrepancy) - Discrepância Média Máxima.

CORAL (CORrelation ALIGNment) - facilita a transferência de domínio no aprendizado.

FedHealth

Relatório NoFed and FedHealth

NoFed									
	<i>C1</i>	<i>C2</i>	<i>C3</i>	<i>C4</i>	<i>C5</i>	<i>C6</i>	<i>P</i>	<i>R</i>	<i>F1</i>
<i>C1</i>	70.4%	7.4%	22.2%	100%	100%	100%	1	0.7	0.83
<i>C2</i>		96.9%	3.1%				0.94	0.97	0.95
<i>C3</i>			100%				0.74	1	0.85
<i>C4</i>							1	1	1
<i>C5</i>					100%		1	1	1
<i>C6</i>						100%	1	1	1
	Average						0.96	0.94	0.94

FedHealth									
	<i>C1</i>	<i>C2</i>	<i>C3</i>	<i>C4</i>	<i>C5</i>	<i>C6</i>	<i>P</i>	<i>R</i>	<i>F1</i>
<i>C1</i>	88.9%	3.7%	7.4%	100%	100%	100%	1	0.89	0.94
<i>C2</i>		100%					0.97	1	0.98
<i>C3</i>			100%				0.91	1	0.95
<i>C4</i>							1	1	1
<i>C5</i>					100%		1	1	1
<i>C6</i>						100%	1	1	1
	Average						0.98	0.98	0.98

Precisão (P)
Recall (R)
Score (F1)

FedHealth

Conclusão

Apresenta resultado superior, melhora significativa ao resultados médios em 5,3%.

Voltado para vestíveis de saúde.

Possui segurança.

FedHealth

Continuidade

No futuro o pesquisador planeja estender o FedHealth para a detecção da doença de Parkinson para que uma possível implantação em hospitais.

Bibliografia

Yiqiang Chen, Xin Qin, Jindong Wang, Chaohui Yu, Wen Gao, FedHealth: A Federated Transfer Learning Framework for Wearable Healthcare. Magazines IEEE Intelligent Systems, July-Aug. 2020, pp. 83-93, vol. 35, DOI Bookmark: 10.1109/MIS.2020.2988604.

Agradecimentos

Meus agradecimentos para:

Prof. Dr. Luiz Fernando Bittencourt: por me ensinar.

Meus Colegas de Sala: por estarem presentes durante minha apresentação.

FIM

Mário A. Costa Jr.

Contato: mariokozta@gmail.com