

# MO809A - Tópicos em Computação Distribuída

**Seminário:** “Quando o Aprendizado Federado encontra a Blockchain: Um novo paradigma do Aprendizado Distribuído”.

Wilson Bagni Junior - 010097


Artigo de base

# When Federated Learning Meets Blockchain: A New Distributed Learning Paradigm

Chuan Ma; Jun Li; Long Shi; Ming Ding; Taotao Wang; Zhu Han; H. Vincent Poor

Publicação: IEEE Computational Intelligence Magazine (Volume: 17, Issue: 3, August 2022)

## When Federated Learning Meets Blockchain: A New Distributed Learning Paradigm



**Chuan Ma, Jun Li, and Long Shi**  
Nanjing University of Science and Technology, CHINA

**Ming Ding**  
CSIRO, AUSTRALIA

**Taotao Wang**  
Shenzhen University, CHINA

**Zhu Han**  
University of Houston, USA, and Kyung Hee University,  
SOUTH KOREA

**H. Vincent Poor**  
Princeton University, USA

*Abstract*—Motivated by the increasingly powerful computing capabilities of end-user equipment, and by the growing privacy concerns over sharing sensitive raw data, a distributed machine learning paradigm known as federated learning (FL) has emerged. By training models locally at each client and aggregating learning models at a central server, FL has the capability to avoid sharing data directly, thereby reducing privacy leakage. However, the conventional FL framework relies heavily on a single central server, and it may fail if such a server behaves maliciously. To address this single point of failure, in this work, a blockchain-assisted decentralized FL framework is investigated, which can prevent malicious clients from poisoning the learning process, and thus provides a self-motivated and reliable learning environment for clients. In

# Trabalhos anteriores

- [5] H. Kim, J. Park, M. Bennis, and S. Kim, "Blockchained on-device federated learning," *IEEE Commun. Lett.*, vol. 24, no. 6, pp. 1279–1283, Jun. 2020, doi: 10.1109/LCOMM.2019.2921755.
- [6] Y. Lu, X. Huang, Y. Dai, S. Maharjan, and Y. Zhang, "Blockchain and federated learning for privacy-preserved data sharing in industrial IoT," *IEEE Trans. Ind. Informat.*, vol. 16, no. 6, pp. 4177–4186, Jun. 2020, doi: 10.1109/TII.2019.2942190.
- [7] X. Bao, C. Su, Y. Xiong, W. Huang, and Y. Hu, "Flchain: A blockchain for auditable federated learning with trust and incentive," in *Proc. 2019 5th Int. Conf. Big Data Comput. Commun. (BIGCOM)*, pp. 151–159, doi: 10.1109/BIGCOM.2019.00030.
- [8] P. K. Sharma, J. H. Park, and K. Cho, "Blockchain and federated learning-based distributed computing defence framework for sustainable society," *Sustain. Cities Soc.*, vol. 59, p. 102,220, 2020.
- [9] S. Wang, "Blockfedml: Blockchained federated machine learning systems," in *Proc. 2019 Int. Conf. Intell. Comput., Autom. Syst. (ICICAS)*, pp. 751–756, doi: 10.1109/ICI-CAS48597.2019.00162.
- [10] Y. Qu, S. R. Pokhrel, S. Garg, L. Gao, and Y. Xiang, "A blockchained federated learning framework for cognitive computing in industry 4.0 networks," *IEEE Trans. Ind. Informat.*, vol. 17, no. 4, pp. 2964–2973, Apr. 2021, doi: 10.1109/TII.2020.3007817.
- [11] S. Otoum, I. Al Ridhawi, and H. Mouftah, "Blockchain-supported federated learning for trustworthy vehicular networks," Dec. 2020, pp. 1–6.

# Trabalhos anteriores

- Propuseram e estudaram integrações entre Aprendizado Federado e Blockchain
- Analisaram algumas questões de segurança e vazamento de informações propondo métodos de controle/mitigação dos problemas
- No geral, tiveram como suposição que a Federação de entidades que compunham a rede (ou parte dela) eram 'confiáveis'.

## Este artigo

O artigo em questão propõe uma estrutura baseada em blockchain (BLochain-Assisted DEcentralized Federated Learning - BLADE-FL) que resolve a vulnerabilidade da centralização de dados em um servidor central e também procura mitigar a ação de usuários mal intencionados que estejam participando da rede.

# Introdução e Motivação

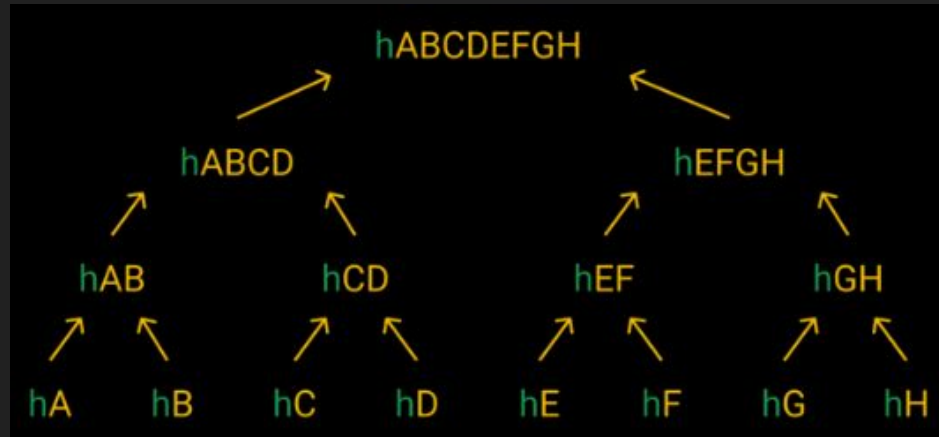
O Aprendizado Federado aproveita o poder computacional de equipamentos da “borda” da rede treinando modelos de maneira distribuída, agregando-os de forma centralizada, muitas vezes evitando vazamento de informações sensíveis.

A concentração realizada na agregação desses modelos num servidor central pode representar um ponto de vulnerabilidade para este paradigma (servidor comprometido/vulnerável, falta de transparência, viés etc)


Para lidar com esse ponto de vulnerabilidade é possível utilizar uma estrutura descentralizada de blockchain. Nela, a agregação dos modelos ocorre de forma descentralizada, auditável e as tarefas de treino do modelo e mineração/verificação dos blocos da blockchain são divididas entre todos os participantes.

# Mas antes de começarmos...o que é blockchain?

É uma estrutura de dados baseada em *Merkle Tree* (árvore de hash) que permite, com uso de recursos de criptografia, manter a integridade de todos os blocos de dados da estrutura. Ideal para uma rede P2P onde os participantes precisam compartilhar e validar informações de forma independente.




# Como um novo bloco é adicionado na rede?



Um novo bloco é adicionado a essa rede através de mecanismos de consenso.

O mecanismo *Proof of Work* (PoW) consiste em resolver um problema computacionalmente difícil. O nó que resolver esse problema ganha o direito de anexar um bloco na rede depois que isso for verificado por outros nós.



Uma vez verificado o novo bloco é incorporado e aceito na rede. Esse processo é chamado de mineração e geralmente as redes de blockchain recompensam o nó da rede que consegue agregar um bloco.



# O framework BLADE-FL

Composto por 3 camadas: **1- Rede**, **2 - Blockchain** e **3 - Aplicação**

**1 - Rede:** Rede do tipo *peer-to-peer* (P2P): Composta por entidades que podem publicar tarefas e treinar modelos

**2 - Blockchain:** Diferente de uma comunidade confiável, as entidades, além de treinar modelos, mineram os blocos para publicar os resultados agregados (auditam os resultados)

**3 - Aplicação:** Através de um contrato inteligente (*Smart Contract* - SM) os eventos do aprendizado federado são executados e controlados.

# Como funciona um contrato inteligente?

O contrato inteligente é uma coleção de códigos de dados que é implementada usando transações assinadas criptograficamente na rede blockchain.

Ele pode conter requisitos a serem atendidos e cláusulas autogerenciáveis de forma que executa transações de forma automática assim que determinadas condições são atendidas.



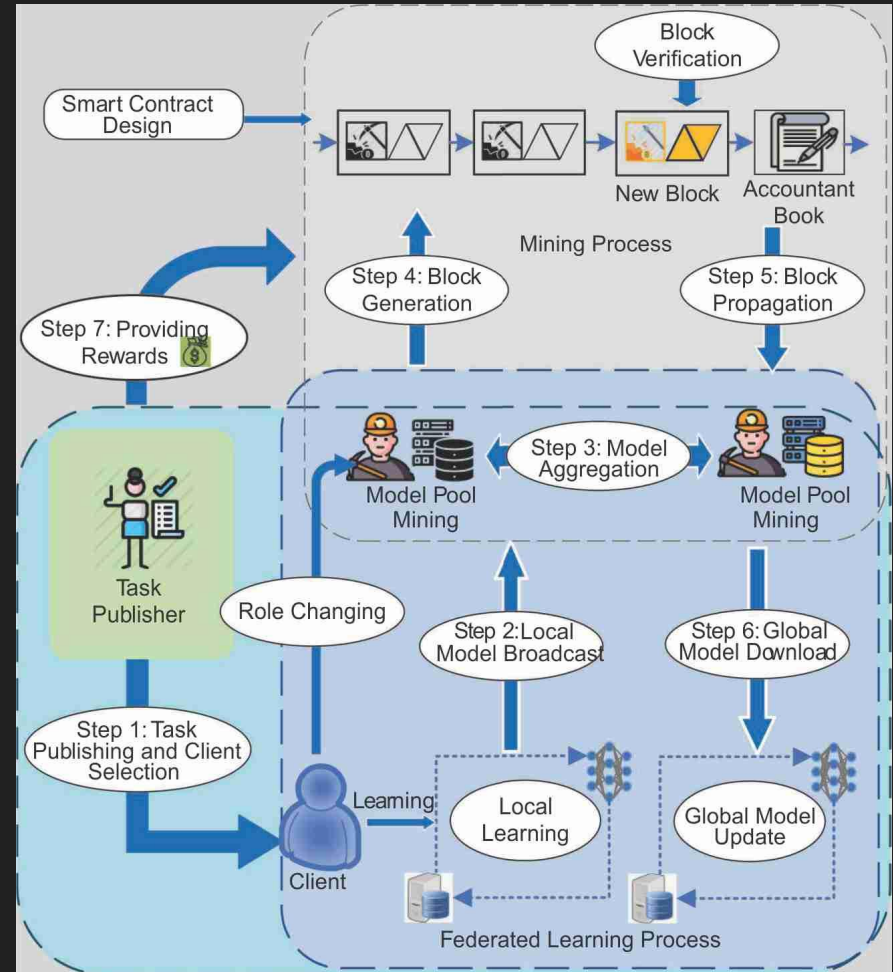
# Workflow - Visão Geral

P2P Network Layer

Blockchain Layer

Application Layer

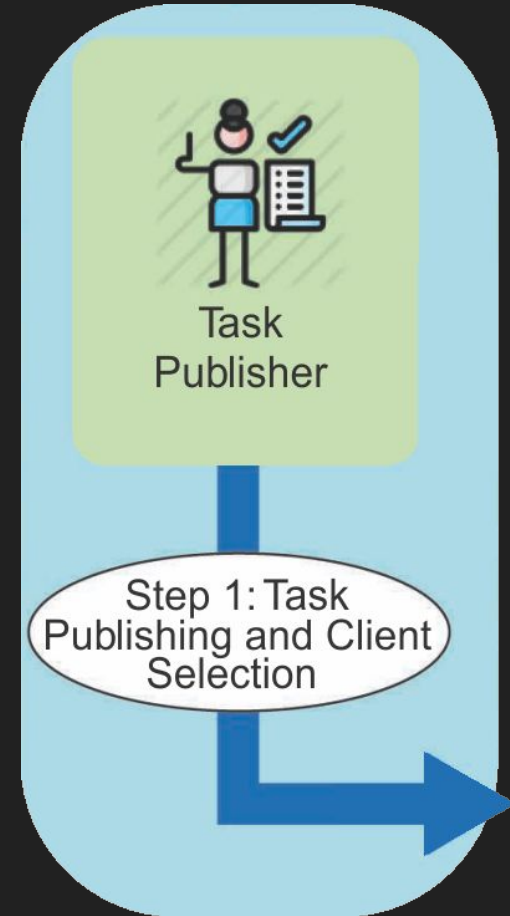
(Cada etapa será detalhada nos próximos slides)



# Workflow em detalhes


**Passo 1** - Um usuário publica uma tarefa de Aprendizado Federado através de um contrato inteligente e deposita uma recompensa (\$\$\$) de incentivo.

O contrato inteligente seleciona nós da rede disponíveis para participar da tarefa de aprendizado.




# Workflow em detalhes

**Passo 2** - Transmissão de modelos locais: Cada cliente treina localmente seu modelo e transmite atualizações locais do modelo pela rede P2P.




# Workflow em detalhes

**Passo 3** - Agregação de modelos: Ao receber atualizações locais de outros nós, cada cliente atualiza o modelo global com base nas regras do contrato inteligente.



# Workflow em detalhes

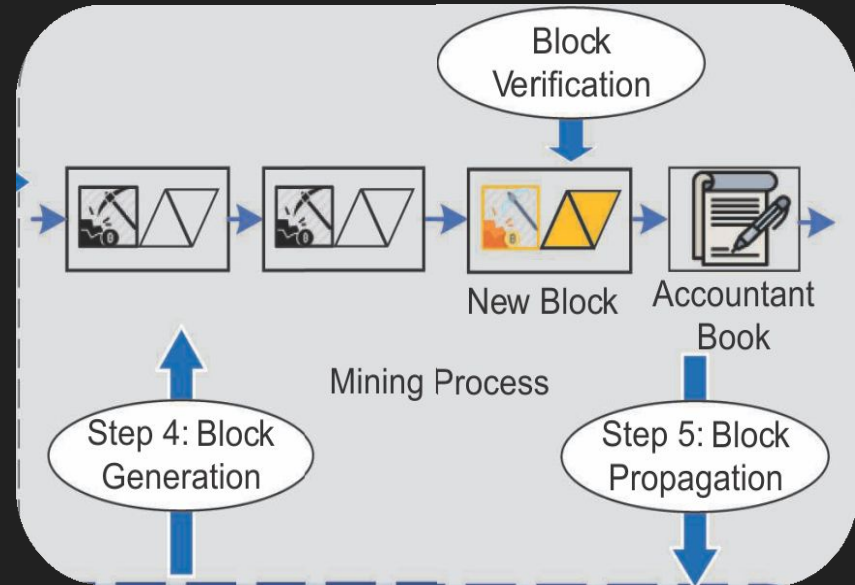
**Passo 4 - Geração de bloco.** Os clientes que estavam treinando modelos trocam de função e passam a atuar como mineradores: gerando um bloco ou recebendo um bloco gerado por outro cliente. Quando um minerador gera um bloco, os outros mineradores verificam o bloco gerado.



# Workflow em detalhes

**Passo 4** - Geração de bloco. Os clientes que estavam treinando modelos trocam de função e passam a atuar como mineradores: gerando um bloco ou recebendo um bloco gerado por outro cliente. Quando um minerador gera um bloco, os outros mineradores verificam o bloco gerado.

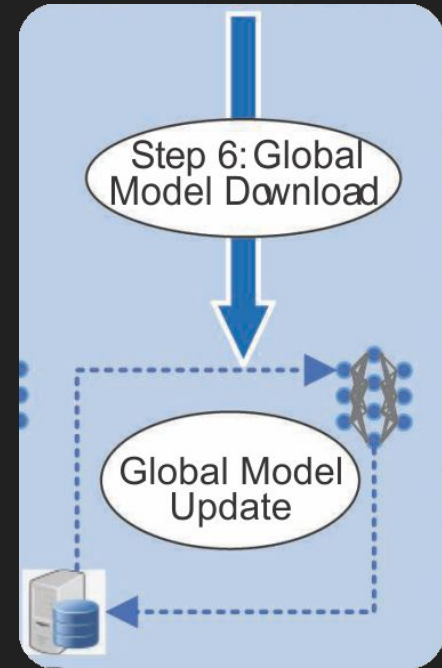
**Passo 5** - Propagação do bloco. Se um bloco é verificado por uma maioria de clientes, ele é anexado à cadeia da blockchain e aceito por toda rede.





# Workflow em detalhes


**Passo 6** - O modelo global é atualizado e repassado a todos os clientes antes da próxima rodada de aprendizado.



# Workflow em detalhes

**Passo 6** - O modelo global é atualizado e repassado a todos os clientes antes da próxima rodada de aprendizado.

**Passo 7** - A recompensa depositada no passo 1 é distribuída entre os participantes de acordo com a relevância da atuação

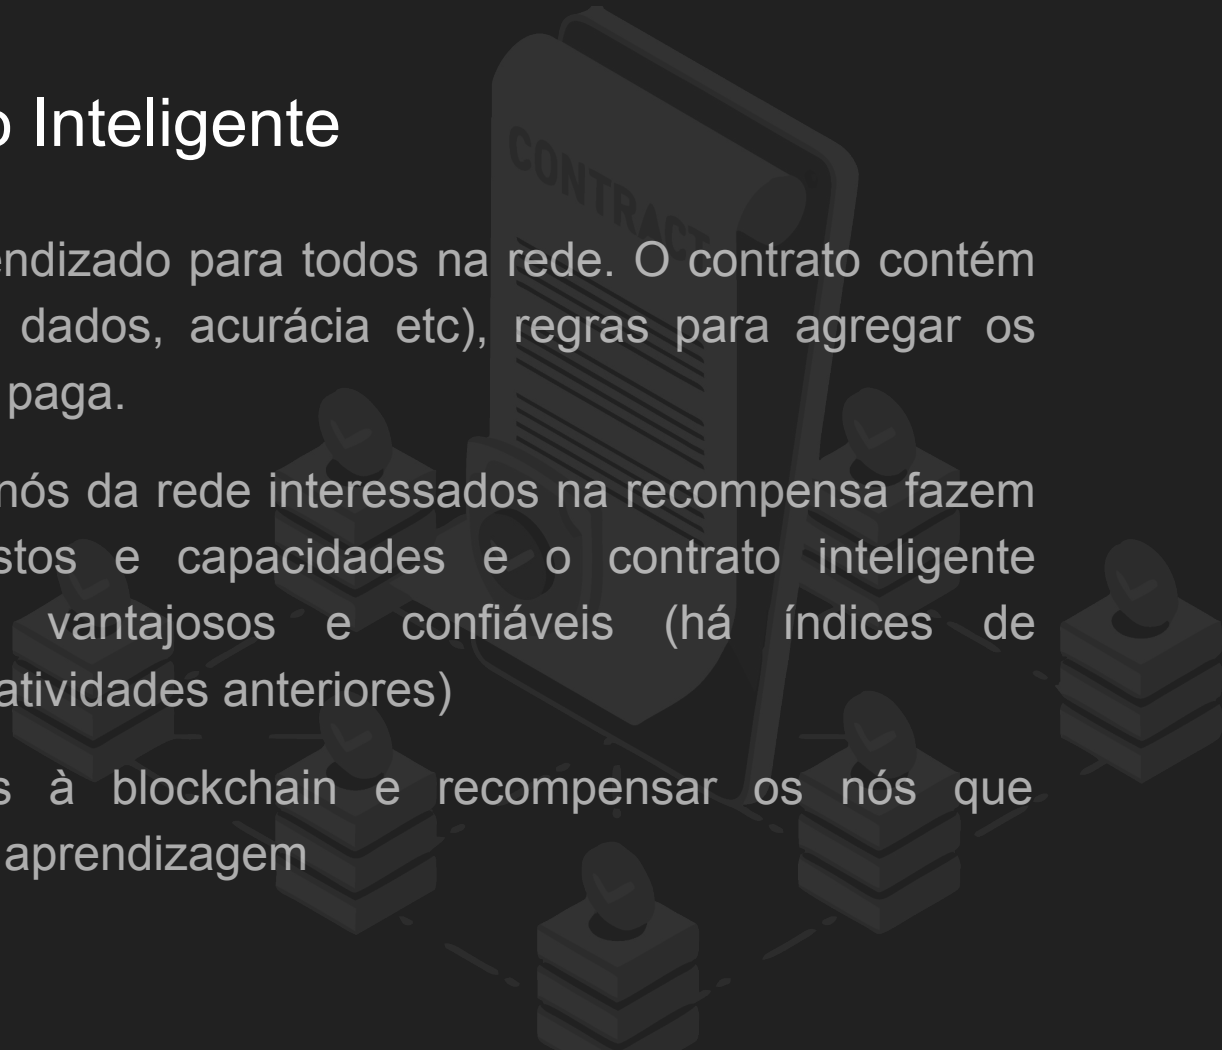


# Funções do Contrato Inteligente

1 - Publicar a tarefa de aprendizado para todos na rede. O contrato contém os requisitos (tamanho dos dados, acurácia etc), regras para agregar os dados e a recompensa a ser paga.

2 - “Leiloar” a atividade. Os nós da rede interessados na recompensa fazem lances indicando seus custos e capacidades e o contrato inteligente selecionará aqueles mais vantajosos e confiáveis (há índices de confiabilidade com base em atividades anteriores)

3 - Agregar os resultados à blockchain e recompensar os nós que participaram do processo de aprendizagem

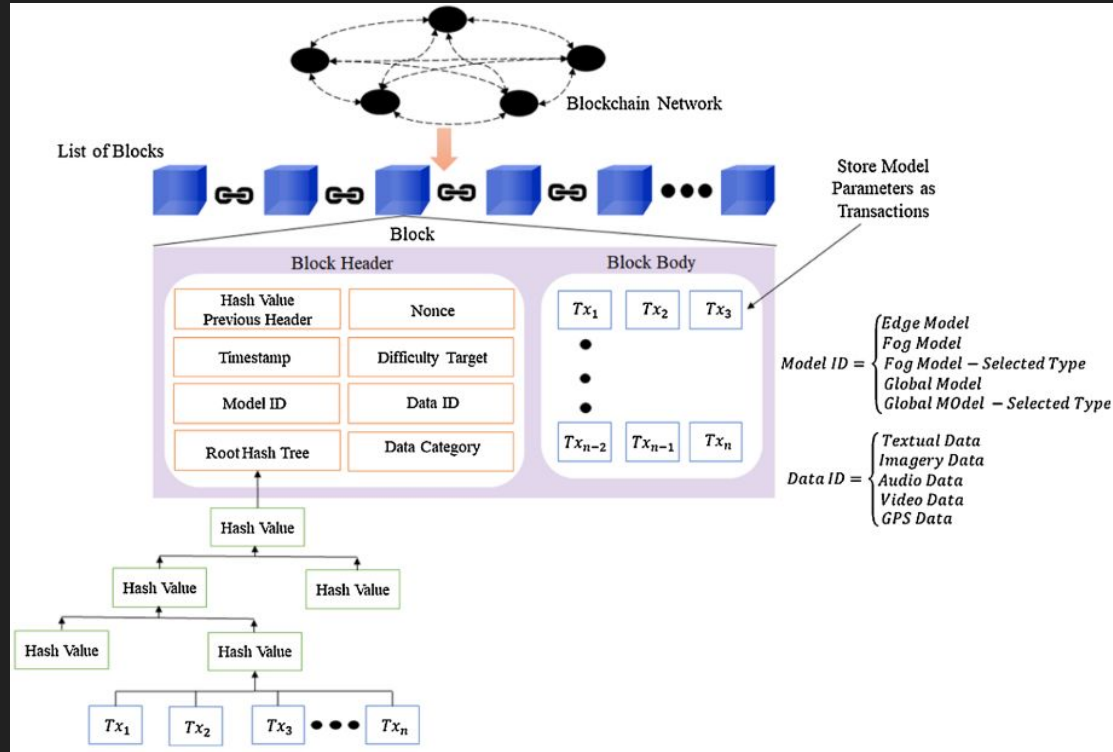


# Pontos-chave do framework

**1 - Atualização e upload do modelo local:** Os nós da rede que vencem o 'leilão' atualizam, de forma paralela, um modelo local de aprendizado de máquina usando o modelo global e suas amostras de dados locais e transmitem seu modelo local atualizado na rede. Essa comunicação pode ser feita na rede P2P com uso de protocolos do tipo "gossip", por exemplo.

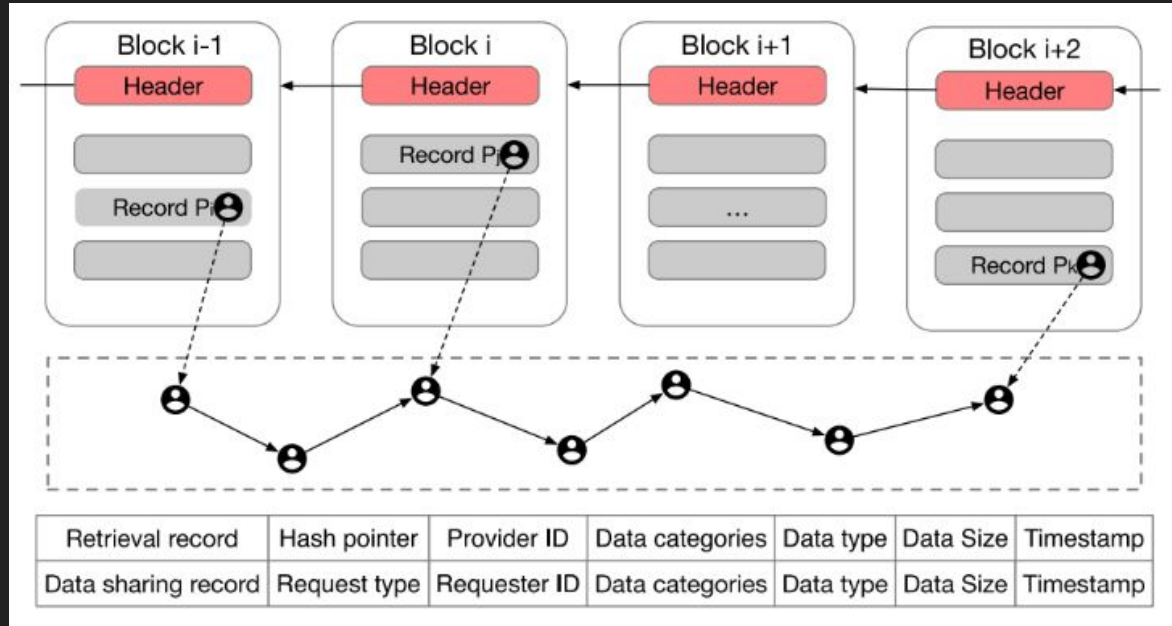
**2 - Agregação dos modelos:** depois de coletar os modelos enviados, cada cliente calcula as atualizações globais do modelo de acordo com a regra de agregação prevista pelo contrato inteligente. O armazenamento pode ser feito na blockchain como um 'livro razão'

# Pontos-chave do framework (continuação)



ARTIGO: BLOCKCHAIN AND FEDERATED LEARNING-BASED DISTRIBUTED COMPUTING  
DEFENCE FRAMEWORK FOR SUSTAINABLE SOCIETY

# Pontos-chave do framework (continuação)




ARTIGO: BLOCKCHAIN AND FEDERATED LEARNING FOR PRIVACY-PRESERVED DATA SHARING IN INDUSTRIAL IoT

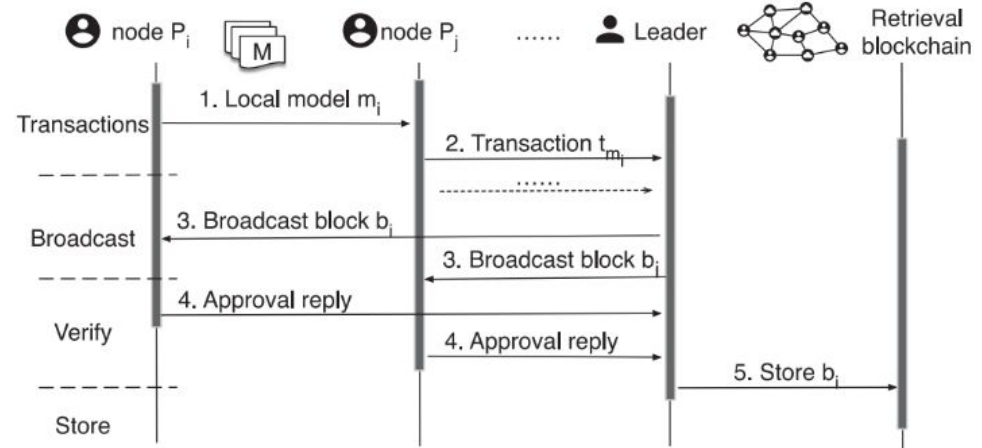
# Pontos-chave do framework (continuação)

**TABLE I**  
RECORD TUPLE OF A MODEL TRANSACTION

Hash pointer	Owner id	Receiver id	Model data	MAE	Timestamp
--------------	----------	-------------	------------	-----	-----------



ARTIGO: BLOCKCHAIN AND  
FEDERATED LEARNING FOR  
PRIVACY-PRESERVED DATA  
SHARING IN INDUSTRIAL IoT



# Pontos-chave do framework (continuação)

**3 - Publicação dos modelos:** blocos gerados são compartilhados na rede e verificados. Nesta etapa são aplicados protocolos de consenso (por exemplo o PoW - *Proof of Work*) para a distribuição de modelos entre os clientes da rede e para a decisão se o bloco será anexado ou rejeitado.

Caso o bloco seja aceito, a atualização da blockchain é repassada a todos os usuários da rede, as recompensas são pagas e um novo ciclo de treinamento pode começar.



# Investigações adicionais (1- privacidade)

Na etapa inicial de treino dos modelos há maior chance de vazamento de informações sensíveis. Trabalhos anteriores lidaram com essa questão separando usuários mineradores daqueles que treinavam os modelos e também admitindo que toda ou parte da rede era confiável.


Este artigo investigou a diminuição do vazamento de informações pela adição de ruído (por exemplo, ruído Gaussiano ou Laplaciano) nos dados a ser efetuada por cada ente de rede.

A quantidade de ruído a ser colocada pode ser um parâmetro de escolha a ser analisado pelo contrato inteligente.

# Investigações adicionais (1- privacidade)

Com a adição de ruído haverá prejuízo no aprendizado, e será necessário encontrar a melhor relação de custo benefício em cada caso.

A performance pode ser melhorada também se o ruído a ser adicionado diminuir a cada rodada de treino.



**FIGURE 2** Learning performance with respect to different privacy levels.

## Investigações adicionais (2- usuários preguiçosos)

Um determinado usuário da rede pode tentar ganhar as recompensas por apenas replicar modelos treinados por outros usuários.

Ao invés de treinar o modelo, quando ele recebe um modelo para verificar, adiciona ruído ou altera levemente os parâmetros e repassa para a rede o modelo como se fosse dele.

Para mitigar esse tipo de problema, o artigo estuda o uso de pseudo-ruído.

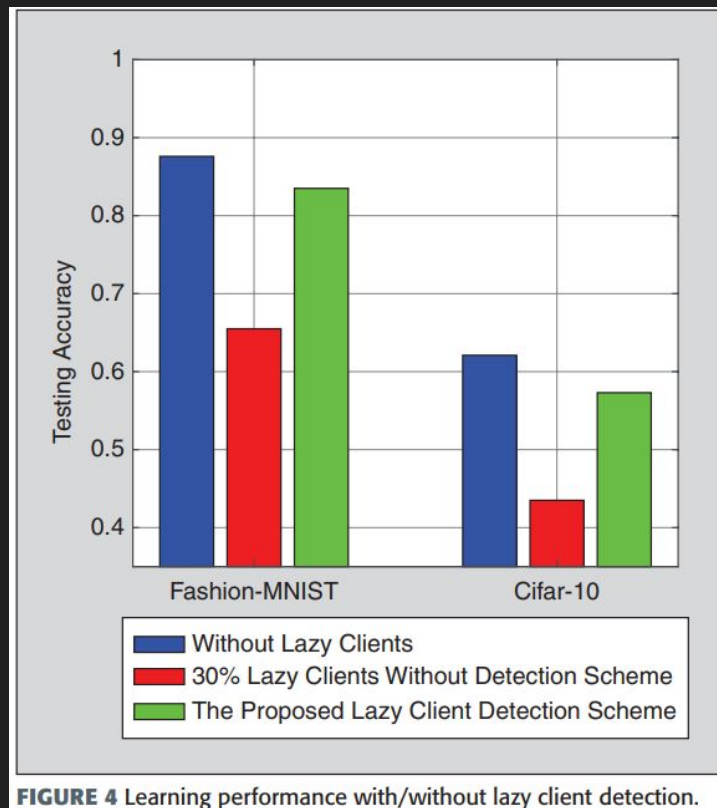
# Investigações adicionais (2- usuários preguiçosos)

Ao verificar o modelo, o usuário inicialmente verifica se ele pode ter sido plagiado. (verificação de correlação cruzada).

Se essa verificação atingir determinado limiar, é detectado o plágio e o usuário preguiçoso é punido na rede.

**TABLE I** Detection rate with different PN sequence powers for Fashion-MNIST and Cifar-10 datasets.

SNR	9 dB	6 dB	3 dB
Fashion-MNIST	0.931	0.989	0.999
Cifar-10	0.925	0.975	0.996

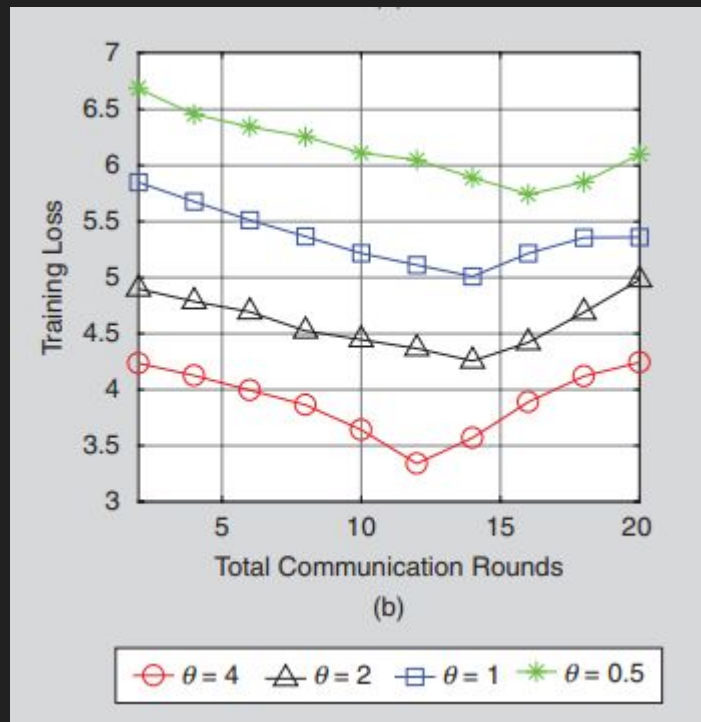


## Investigações adicionais (3- alocação de recursos)

O artigo estuda também o impacto da razão entre os recursos que cada cliente usa com Treino e Mineração.

No gráfico, quanto maior theta, mais recursos são gastos no treino do modelo. Os dados foram treinados usando a base Cifar-10.

Esta razão impacta diretamente na quantidade de rounds ótima para treino dos modelos.



Dúvidas?